¿Me paso o no me paso?: Asistente de consumo eléctrico para el hogar

Tiago Maidana, Rodrigo Bulggiani, Romina Guzmán, Francisco Elías Campos y Juan M. Flescia

ISFDYT N.º 57

Procesamiento de Lenguaje Automático, 2.º año, Grupo 6

Santiago Chiale

3 de noviembre de 2026

Resumen

Este informe presenta *¿Me paso o no me paso?*, una aplicación web desarrollada en Python con Streamlit que permite simular el consumo eléctrico de una vivienda, estimar la factura residencial de EDEA y anticipar si el consumo de las próximas 24 horas superará una meta diaria de 13,33 kWh, equivalente al límite del tramo R3 del cuadro tarifario. Se entrenaron un modelo de regresión (KNN, k = 50) y un clasificador (GaussianNB) con el conjunto de datos público de consumo de un hogar de Sceaux, Francia, reescalado a la realidad argentina mediante un factor de 0,514. En el conjunto de prueba, la regresión alcanzó un error absoluto medio de 2,249 kWh y un R^2 de 0,371, mientras que el clasificador obtuvo un recall de 0,700 y un F1 de 0,646. Con una ponderación de costos de 3 a 1 entre falsos negativos y falsos positivos, el clasificador directo tuvo menor costo (2282) que la regresión con umbral (2706), aunque con más falsas alarmas. El informe documenta la preparación de los datos, la prevención de fuga de información, la integración de los modelos en la aplicación, la verificación mediante 33 pruebas automatizadas y las limitaciones del enfoque, entre ellas el uso de un único hogar y el cambio de distribución entre períodos.

Palabras clave: aprendizaje automático, consumo eléctrico, regresión, clasificación, Streamlit, EDEA

¿Me paso o no me paso?: Asistente de consumo eléctrico para el hogar

Introducción

¿Me paso o no me paso? es una aplicación web desarrollada en Python con Streamlit que permite armar una vivienda electrodoméstico por electrodoméstico, calcular su consumo mensual, estimar la factura residencial de EDEA y anticipar si el consumo de las próximas 24 horas superará una meta diaria.

El proyecto resuelve dos tareas relacionadas sobre el mismo conjunto de datos:

Tabla 1

Tareas que resuelve el proyecto

Tarea	Pregunta	Resultado que entrega
Regresión	¿Cuánta energía se consumirá en las próximas 24 horas?	Un valor numérico en kWh
Clasificación	¿Se superará la meta diaria?	Una alerta binaria: sí o no

La meta se fijó en **13,33 kWh por día**, equivalentes a **400 kWh por mes**, porque ese es el límite del tramo R3 del cuadro tarifario de EDEA. Por encima de ese valor, la factura pasa al tramo R4, con cargos más altos.

Los modelos se entrenaron con el dataset público UCI *Individual Household Electric Power Consumption*, de un hogar de Sceaux, Francia, entre 2006 y 2010 (UCI Machine Learning Repository, s. f.). Como ese hogar consume mucho más que uno argentino, toda su energía se reescaló por un factor de **0,514** para que su mediana diaria coincida con la meta de 13,33 kWh.

Los resultados principales en el conjunto de prueba fueron:

Tabla 2

Resultados principales en el conjunto de prueba

Sistema	Resultado
Regresión KNN k=50	MAE 2,249 kWh; RMSE 2,954 kWh; R^2 0,371
Clasificación GaussianNB	Accuracy 0,738; precision 0,600; recall 0,700; F1 0,646
Comparación integrada	El clasificador directo tuvo menor costo ponderado que la regresión + umbral (2282 frente a 2706)

La aplicación integra los dos modelos ya entrenados, sin reentrenar en cada solicitud. Además, incluye un simulador determinista de consumo y facturación, un ambiente 3D, lectura de facturas en PDF o foto y una sección de análisis reproducible.

El repositorio contiene **33 pruebas automatizadas**, todas aprobadas en la verificación local. La aplicación está publicada y el código de entrenamiento y evaluación puede reproducirse desde el notebook o desde `entrenamiento_modelos.py`.

La aplicación publicada (Maidana et al., 2026a) y el código fuente (Maidana et al., 2026b) están disponibles en línea.

Problemática y propuesta

La factura de luz informa un único dato global: los kWh consumidos en el período. No indica qué electrodoméstico consumió cada parte, cuánto cuesta cada equipo, cuánto se paga en modo standby ni si el consumo del día siguiente hará superar un límite relevante.

Esa falta de información tiene consecuencias concretas:

- el usuario se entera del exceso cuando llega la factura, cuando ya no puede corregirlo;
- el subsidio y los tramos tarifarios tienen topes que cambian el precio por kWh;
- los artefactos con motores y compresores pueden afectar el factor de potencia;
- los hábitos de uso y el consumo fantasma suelen pasar desapercibidos.

La propuesta consiste en una aplicación que permita:

1. armar la casa con perfiles y electrodomésticos;
2. estimar el consumo mensual y el costo con el cuadro tarifario de EDEA;
3. comparar escenarios con y sin subsidio;
4. predecir el consumo de las próximas 24 horas;
5. avisar si se superará la meta diaria;
6. calibrar la simulación con una factura real;
7. explicar los datos, los modelos, las métricas y las limitaciones.

El usuario de la predicción es el titular del hogar. La decisión que habilita la aplicación es anticipar el consumo para postergar o reducir el uso de equipos, revisar los artefactos que más consumen y evitar pasar de tramo tarifario.

Objetivos

Objetivo general

Desarrollar una aplicación web que integre un modelo de regresión y un modelo de clasificación para estimar el consumo eléctrico de un hogar y anticipar si se superará una meta diaria, acompañando el resultado con una explicación comprensible y una estimación de costos.

Objetivos específicos

- Documentar el origen, la preparación y las limitaciones de los datos.
- Construir una variable numérica y una clase binaria derivada de un umbral justificado.
- Comparar modelos obligatorios contra sus baselines.
- Evaluar la regresión con MAE, RMSE, R^2, residuos y análisis de errores.
- Evaluar la clasificación con accuracy, precision, recall, F1 y matriz de confusión.
- Comparar la alerta del clasificador directo con la alerta derivada de la regresión + umbral.
- Definir un esquema de costos para falsos positivos y falsos negativos.
- Integrar los modelos entrenados en una aplicación web que solo ejecute `predict`.
- Publicar la aplicación y verificar su funcionamiento.
- Asegurar la reproducibilidad mediante notebook, requirements, README y pruebas.

Alcance funcional de la aplicación

La aplicación tiene cinco pantallas principales.

Inicio

Pantalla de presentación que explica el propósito del proyecto y ofrece accesos directos a las cuatro herramientas principales: Mi casa, Ambiente 3D, Factura y Análisis.

Mi casa

Es el núcleo de la aplicación. Se organiza en cuatro pasos de arriba hacia abajo.

Paso 1: Tu situación

- selección del escenario tarifario: sin subsidio, subsidio nacional SEF, tarifa social provincial o tarifa social + SEF;

- consumo de base de la casa, en watts, para equipos siempre enchufados que no se cargan individualmente;
- botón para reiniciar la casa completa.

Paso 2: Armá tu casa

- catálogo de 26 electrodomésticos;
- perfiles precargados: ejemplo de la propuesta, una persona, pareja y familia;
- tarjetas editables por equipo, con cantidad, horas de uso, horas conectado, días por semana, ciclos o kWh por año según el modo;
- variantes por tamaño o potencia, por ejemplo TV de 32 a 65 pulgadas, aire de 2.250 a 6.000 frigorías, heladera chica, mediana o grande;
- explicación emergente de los kWh y del costo de cada equipo.

Paso 3: Tu factura de EDEA

- cálculo mensual de consumo activo, standby y consumo de base;
- factura renglón por renglón, como la boleta;
- comparación de escenarios con y sin subsidio;
- ranking de los equipos que más consumen;
- detección del consumo fantasma;
- consejos de ahorro.

Paso 4: ¿Mañana te pasás de la meta?

- estimación de los kWh de las próximas 24 horas con regresión;
- alerta directa del clasificador;
- comparación entre ambas alertas;
- semáforo de resultado;
- costo estimado de las dos cuotas mensuales si se mantiene el consumo;
- explicación de qué variables recibió el modelo.

Ambiente 3D

La misma casa se representa en tres ambientes: living, cocina y dormitorio. El usuario puede:

- arrastrar muebles y electrodomésticos;
- rotar objetos;

- mover artefactos entre ambientes;
- ver el consumo de cada equipo;
- simular un día de uso;
- agregar o quitar muebles decorativos.

La escena es un SVG isométrico propio, conectado con Streamlit Components. Los muebles no consumen energía; los electrodomésticos sí se vinculan con el cálculo de Mi casa.

Factura

Permite leer una factura real y compararla con la simulación.

- carga de PDF, JPG, PNG o WebP de hasta 10 MB;
- lectura de PDF digital con `pypdf`;
- lectura de fotos con OCR de Tesseract en español;
- lectura de códigos QR y de barras con `zxing-cpp`;
- extracción de consumo, período, importe, vencimiento y subsidio;
- confirmación y corrección manual de los datos detectados;
- comparación lado a lado entre la factura real y la factura simulada;
- cálculo del factor de calibración entre ambas;
- ajuste opcional de toda la simulación.

La imagen se procesa en memoria y no se guarda. Solo se conservan los campos numéricos y los renglones necesarios para dibujar la boleta. No se guardan nombre, dirección ni NIS.

Análisis

Muestra el trabajo con el dataset y los modelos:

- origen de los datos;
- preparación y control de calidad;
- definición de la variable objetivo y del umbral;
- reescalado a un hogar argentino;
- separación temporal de entrenamiento, validación y prueba;
- baselines y modelos comparados;
- métricas de regresión y clasificación;
- comparación de las dos formas de generar la alerta;

- análisis de errores y casos cercanos al umbral;
- limitaciones y mejoras pendientes;
- última predicción: qué variables recibió el modelo.

Arquitectura y tecnologías

Stack técnico

Tabla 3

Componentes tecnológicos de la aplicación

Componente	Tecnología
Lenguaje	Python 3.11 o superior; Python 3.12 en la nube
Aplicación web	Streamlit 1.57
Modelos	scikit-learn 1.8 y joblib
Datos y tablas	pandas 2.3 y numpy 2.3
Gráficos	Plotly 6.7
Lectura de PDF	pypdf 6.21
OCR	Tesseract + pytesseract 0.3.13 + Pillow 11.3
QR y códigos de barras	zxing-cpp 3.1.1
Ambiente 3D	SVG isométrico propio + JavaScript + Streamlit Components
Persistencia	Archivos JSON en `sesiones/` y código en la URL
Base de datos	No utiliza

Flujo de ejecución

1. `streamlit_app.py` configura la página.
2. Se inicializa el estado de la sesión.
3. Se restaura la casa guardada a partir del código de la URL.
4. Se sincronizan los widgets con las instancias de electrodomésticos.
5. Se aplican los estilos y el navbar propio.
6. Se ejecuta la página seleccionada.
7. Se muestra el resumen de la casa, excepto en Inicio y Análisis.
8. Se guarda la casa al final de cada ejecución.

Organización del código

```
streamlit_app.py                  Punto de entrada
app_pages/
  inicio.py                       Pantalla de inicio
  casa.py                         Mi casa (pasos 1 a 4)
  ambiente.py                     Ambiente 3D
  factura.py                      Lectura y comparación de facturas
  analisis.py                     Documentación del análisis
simulador/
  calculo.py                      Motor de cálculo y facturación
  estado.py                       Estado de la sesión
  ui.py                           Navbar, estilos y tarjetas
  variantes.py                    Variantes de electrodomésticos
  prediccion.py                   Carga de modelos y armado de variables
  vista_prediccion.py             Paso 4 de Mi casa
  factura.py                      PDF, OCR y QR
  graficos.py                     Gráficos Plotly
  guardado.py                     Persistencia de la casa
  escena.py                       Integración del ambiente 3D
  componentes/                    SVG, JavaScript y CSS del 3D
  datos/datos.json                Catálogo, perfiles y muebles
modelos/
  reg_24h.pkl                     Regresión entrenada
  clf_me_paso.pkl                 Clasificación entrenada
datos/
  tarifas_edea.csv                Cuadro tarifario
  impuestos_residenciales.csv     Impuestos
  electrodomesticos_eficiencia.csv
  FUENTES.md                      Fuentes y limitaciones
explicaciones/
  README_ANALISIS.md              Análisis detallado
notebooks/
  entrenamiento_modelos.ipynb     Entrenamiento reproducible
tests/
  test_calculo.py
  test_factura.py
  test_entrenamiento_modelos.py
entrenamiento_modelos.py          Script de entrenamiento y guardado
requirements.txt
packages.txt
```

Datos y fuentes

Dataset de aprendizaje automático

El conjunto de datos de aprendizaje automático proviene del UCI Machine Learning Repository (s. f.) y se resume en la Tabla 4.

Tabla 4

Ficha del conjunto de datos de consumo eléctrico

Campo	Detalle
Nombre	Individual Household Electric Power Consumption
Origen	UCI Machine Learning Repository
Lugar	Sceaux, Francia
Período	diciembre de 2006 a noviembre de 2010
Registros	2.075.259 mediciones por minuto
Variables originales	potencia activa, potencia reactiva, voltaje, intensidad, tres submedidores
Licencia	CC BY 4.0
Enlace	https://archive.ics.uci.edu/dataset/235/individual+household+electric+power+consumption

Nota. Elaboración propia a partir de UCI Machine Learning Repository (s. f.).

El archivo completo pesa aproximadamente 133 MB y no se sube al repositorio. El script de entrenamiento lo lee desde `datos/crudos/` o, si no está, lo descarga desde UCI y lo guarda en la caché local del usuario.

Datos meteorológicos

Se utiliza `clima_sceaux.csv`, con temperatura diaria del mismo lugar entre 2006 y 2011, obtenida de Open-Meteo Historical Weather API (Open-Meteo, s. f.). El entrenamiento usa la temperatura del último día completo como aproximación por persistencia, para no utilizar información futura.

Dataset de eficiencia de electrodomésticos

Los datos de eficiencia energética de electrodomésticos provienen del programa GEMS del Gobierno de Australia (s. f.) y se resumen en la Tabla 5.

Tabla 5

Ficha del conjunto de datos de eficiencia de electrodomésticos

Campo	Detalle
Nombre	Energy Rating for Household Appliances
Origen	Gobierno de Australia, programa GEMS
Registros	15.342 modelos
Licencia	CC BY 3.0 Australia
Uso	Valores estándar de heladeras, freezers, aires y televisores
Enlace	https://data.gov.au/data/dataset/energy-rating-for-household-appliances

Nota. Elaboración propia a partir de Gobierno de Australia (s. f.).

Los valores de heladera, freezer, aire y TV se obtuvieron de la mediana de modelos reales agrupados por capacidad o potencia. Los demás electrodomésticos usan valores típicos

declarados como supuestos.

Tarifas e impuestos

Las tarifas y los impuestos aplicados surgen de la Resolución MIySP N.º 682/2026 (Organismo de Control de Energía Eléctrica de la Provincia de Buenos Aires [OCEBA], 2026) y se resumen en la Tabla 6.

Tabla 6

Marco tarifario e impuestos aplicados

Campo	Detalle
Norma	Resolución MIySP N.º 682/2026
Autoridad	OCEBA, Provincia de Buenos Aires
Vigencia	Consumos desde el 1/9/2026
Categoría	T1R residencial
Tramos	R1 a R7
Escenarios	sin subsidio, SEF, tarifa social provincial, tarifa social + SEF
Impuestos	IVA 21 %, Ley 10740 18 %, Ley 11769, Fondo Provincial de Compensaciones y Decreto-Ley 7290
Alicuota total	54,501 % sin subsidio; 50,511 % con SEF o tarifa social
Enlace	https://oceba.gba.gov.ar/nueva_web/s.php?i=17

Nota. Elaboración propia a partir de OCEBA (2026).

El subsidio cambia el precio del kWh, no la cantidad consumida. La aplicación calcula la factura por tramos, con cargo fijo, cargo variable, Cargo Transición Tarifaria, bonificaciones e impuestos.

Privacidad

No se utilizan datos personales identificables. Las facturas escaneadas se procesan en memoria y se descartan. El guardado de la casa solo conserva electrodomésticos, consumos, tarifas elegidas, ajustes y muebles del ambiente 3D.

Preparación de datos y protocolo de evaluación

Unidad de análisis

Cada fila representa un **momento de consulta horario**. A partir de las mediciones de esa hora y de las 24 horas anteriores, el modelo predice la energía que se consumirá en las **24 horas siguientes**.

- Variable numérica: energía activa de las próximas 24 horas, en kWh.
- Variable binaria: `me_paso = 1` si esa energía supera la meta diaria.

- Meta: 13,33 kWh por día.

Limpieza y control de calidad

La auditoría de la corrida registró:

Tabla 7

Controles de calidad de los datos

Control	Resultado
Filas descargadas	2.075.259
Celdas faltantes antes de limpiar	155.874
Marcas de tiempo inválidas	0
Filas duplicadas exactas	0
Filas con valores físicamente imposibles	0
Horas completas aceptadas	34.151
Filas supervisadas finales	32.520

Una hora se acepta si las seis mediciones tienen al menos 45 minutos válidos de 60. No se imputan faltantes. Se excluyen potencias negativas, potencia activa superior a 15 kW y voltajes no positivos.

Variables predictoras

Se utilizan 16 variables:

Tabla 8

Variables predictoras del modelo

Variable	Descripción
`kwh_h`	Consumo de la hora de consulta
`active_24`	Energía activa de las últimas 24 horas
`active_prevweek`	Energía activa de las mismas 24 horas de la semana anterior
`reactive_24`	Energía reactiva de las últimas 24 horas
`cosphi_24`	Factor de potencia derivado: activa / raíz(activa² + reactiva²)
`sub1_24`	Submedidor de cocina
`sub2_24`	Submedidor de lavadero, heladera y luces
`sub3_24`	Submedidor de termotanque y climatización
`volt_24`	Voltaje medio de las últimas 24 horas
`hour`	Hora del día
`dayofweek`	Día de la semana
`month`	Mes
`is_weekend`	Indicador de fin de semana
`is_feriado`	Indicador de feriado
`temp_actual`	Temperatura actual
`temp_next24`	Temperatura prevista para las próximas 24 horas

Prevención de fuga de información

Se aplicaron las siguientes medidas:

- solo se usan mediciones anteriores al momento de la predicción;
- no se incluye el objetivo futuro ni su clase entre los predictores;
- no se usa la intensidad como atajo, porque es potencia dividida por voltaje;
- la separación es cronológica, no aleatoria;
- se purgan 24 horas en los límites entre conjuntos para evitar solapamiento de ventanas objetivo;
- el `StandardScaler` está dentro del `Pipeline` y se ajusta solo con entrenamiento;
- la meta se fijó antes de evaluar y no se optimizó mirando el conjunto de prueba;
- regresión, clasificación y comparación de alertas usan exactamente los mismos casos de prueba.

Separación de datos

Tabla 9

Casos y proporción de excesos por conjunto de datos

Conjunto	Casos	Proporción de excesos
Entrenamiento	22.740	49,1 %
Validación	4.854	70,5 %
Prueba	4.878	34,2 %

La proporción de excesos cambia entre períodos. Eso es una señal de cambio de distribución y se documenta como limitación: un modelo elegido en validación puede no mantener el mismo comportamiento en otro período.

Reescalado a un hogar argentino

El hogar de Sceaux tiene una mediana de 25,92 kWh por día, muy superior a la meta argentina de 13,33 kWh. Sin reescalar, el 91 % de los días superaría la meta y el clasificador aprendería a responder casi siempre “te pasás”.

Por eso se multiplica toda la energía del hogar por:

```
factor = 13,33 / 25,92 = 0,514449...
```

Así la mediana diaria pasa a 13,33 kWh y la mitad de los días supera la meta. El voltaje no se modifica porque no es energía. El cos φ tampoco cambia porque la energía activa y la

reactiva se escalan por igual.

Las métricas de clasificación no cambian con el reescalado. Los errores de regresión quedan expresados en la escala argentina.

Modelos de aprendizaje automático

Modelos comparados

Regresión

- `DummyRegressor` con estrategia de media;
- `DecisionTreeRegressor` con profundidades 3, 6, 12 y sin límite;
- `KNeighborsRegressor` con k = 5, 25 y 50, con `StandardScaler` dentro de un `Pipeline`.

Clasificación

- `DummyClassifier` con estrategia de clase mayoritaria;
- `DecisionTreeClassifier` con profundidades 3, 6, 12 y sin límite;
- `KNeighborsClassifier` con k = 5, 25 y 50, con `StandardScaler` dentro de un `Pipeline`;
- `GaussianNB`.

La selección se realizó con validación:

- regresión: menor MAE;
- clasificación: menor costo relativo y, ante empate, mayor F1.

El conjunto de prueba se reservó para la evaluación final.

Resultados de regresión

Tabla 10

Resultados de los modelos de regresión

Modelo	MAE validación (kWh)	MAE prueba (kWh)	RMSE prueba (kWh)	R^2 prueba
DummyRegressor (media)	3,261	3,165	—	—
KNN k=25	3,004	2,345	3,108	0,304
KNN k=50	2,846	2,249	2,954	0,371
Árbol profundidad 6	—	2,395	3,208	0,258

El modelo elegido y usado por la aplicación es **KNN k=50** con `StandardScaler`. Supera al baseline: su MAE de prueba es 2,249 kWh frente a 3,165 kWh del `DummyRegressor`.

El MAE significa que, en promedio, la estimación se aleja 2,249 kWh del valor real. No es una probabilidad de acierto. El R^2 de 0,371 indica que el modelo explica una parte de la variabilidad, pero deja un margen importante sin explicar.

Resultados de clasificación

Tabla 11

Resultados de los modelos de clasificación

Modelo	Accuracy	Precision	Recall	F1	TN	FP	FN	TP
DummyClassifier	0,658	—	0,000	—	—	—	1.669	0
GaussianNB	0,738	0,600	0,700	0,646	2.430	779	501	1.168

GaussianNB fue el clasificador elegido en validación y es el que usa la aplicación. En prueba detectó el 70 % de los excesos, pero dejó pasar 501 casos de exceso y generó 779 falsas alarmas.

El baseline mayoritario tuvo una accuracy de 0,658, pero no detectó ningún exceso. Eso muestra por qué la accuracy sola no alcanza para evaluar una alerta: un modelo que siempre dice “no te pasás” puede tener una accuracy aparentemente razonable y un recall nulo.

Comparación integrada de alertas

Se compararon los dos mecanismos exigidos por la consigna sobre los mismos 4.878 casos de prueba:

- **Regresión + umbral:** se estima el valor numérico y luego se compara con la meta.
- **Clasificador directo:** se predice directamente la clase.

Tabla 12

Comparación de las alertas sobre el conjunto de prueba

Sistema	Accuracy	Precision	Recall	F1	TN	FP	FN	TP	Costo
Regresión KNN k=50 + meta	0,735	0,621	0,577	0,598	2.621	588	706	963	2.706
GaussianNB directo	0,738	0,600	0,700	0,646	2.430	779	501	1.168	2.282

Las alertas coincidieron en **83,8 %** de los casos.

El esquema de costos asigna un peso relativo de **3** a un falso negativo y **1** a un falso positivo. La justificación es que un falso negativo puede dejar al usuario sin aviso frente a un gasto inesperado, mientras que un falso positivo solo genera una advertencia innecesaria. No es una estimación monetaria, sino una ponderación explícita de decisión.

Con ese criterio y en este período de prueba, el clasificador directo tuvo menor costo observado y mayor recall. Sin embargo, produce más falsas alarmas y la proporción de excesos cambia entre períodos, por lo que no se recomienda como decisión automática sin supervisión.

Errores y casos cercanos al umbral

Los casos cercanos a la meta son los más difíciles:

- El 4/6/2010 a las 13 h el consumo real fue 13,341 kWh, apenas 0,007 kWh por encima de la meta. Ambas alertas indicaron que no se superaba.
- El 17/10/2010 a las 22 h el consumo real fue 22,979 kWh y la regresión estimó 9,371 kWh.
- El 21/11/2010 a las 7 h el consumo real fue 7,656 kWh y la regresión estimó 20,596 kWh.
- El 12/5/2010 a las 23 h el consumo real fue 13,327 kWh, 0,006 kWh por debajo de la meta, y GaussianNB indicó exceso.

Estos ejemplos muestran que un error numérico pequeño puede cambiar por completo la alerta cuando el caso está cerca del umbral. Por eso la aplicación muestra una zona gris cuando la estimación está dentro del MAE respecto de la meta.

Integración de los modelos en la aplicación

La aplicación no entrena modelos. Carga los Pipelines guardados en `modelos/` y ejecuta `predict`.

Construcción de las 16 variables en la app

Tabla 13

Construcción de las 16 variables en la aplicación

Variable	Cómo se obtiene en la aplicación
`kwh_h`	Consumo de la hora seleccionada según la curva de la casa o la factura
`active_24`	Consumo diario de la casa o consumo de la factura dividido por los días
`active_prevweek`	Se aproxima con el consumo diario actual porque no hay historial semanal
`reactive_24`	Valor típico del dataset reescalado: 1,5 kVArh por día
`cosphi_24`	Se calcula con la activa y la reactiva anteriores
`sub1_24`	Consumo diario agrupado de cocina
`sub2_24`	Consumo diario agrupado de lavadero, heladera y luces
`sub3_24`	Consumo diario agrupado de termotanque y climatización
`volt_24`	Valor fijo de 240 V, media del dataset
`hour`	Hora seleccionada
`dayofweek`	Día de la semana de la fecha elegida
`month`	Mes desplazado seis meses para invertir las estaciones
`is_weekend`	Indicador derivado del día de la semana
`is_feriado`	Feriado seleccionado o feriado nacional argentino de fecha fija
`temp_actual`	Temperatura de hoy ingresada por el usuario; inicia en 20 °C
`temp_next24`	Temperatura de mañana ingresada por el usuario; inicia en 20 °C

Presentación del resultado

La aplicación muestra:

- consumo diario actual;
- consumo estimado para las próximas 24 horas, con el MAE;
- meta diaria;
- proyección mensual y costo de las dos cuotas;
- alerta de la regresión + meta;
- alerta del clasificador directo;
- coincidencia o desacuerdo;
- zona gris si la estimación está dentro del MAE;
- interpretación del submedidor que más consume;
- advertencia sobre las limitaciones.

El semáforo se define así:

Tabla 14

Definición del semáforo de resultado

Color	Significado
Verde	Ambos modelos indican que no se supera la meta y la estimación está fuera de la zona gris
Amarillo	Los modelos no coinciden o la estimación está dentro del MAE respecto de la meta
Rojo	Ambos modelos indican que se supera la meta

El semáforo comunica incertidumbre. No es una probabilidad ni una garantía.

Validación de entradas

La aplicación valida, entre otros:

- cantidad de equipos entre 1 y 20;
- horas conectado entre 0 y 24;
- horas de uso no mayores que las horas conectado;
- días por semana entre 1 y 7;
- ciclos por semana entre 0 y 21;
- kWh por año entre 0 y 3.000;
- potencia entre 0 y 10.000 W;
- standby entre 0 y 100 W;
- consumo de factura entre 0 y 2.000 kWh;
- período de factura entre 25 y 65 días.

Cálculo determinista y facturación EDEA

Es importante distinguir dos partes de la aplicación:

Tabla 15

Naturaleza de las partes de la aplicación

Parte	Naturaleza	Qué hace
Cálculo de consumo y factura	Determinista, sin aprendizaje automático	Aplica fórmulas y el cuadro tarifario
Predicción de las próximas 24 h	Aprendizaje automático	Carga modelos entrenados y ejecuta `predict`

El cálculo determinista usa cuatro modos:

Tabla 16

Modos de cálculo determinista del consumo mensual

Modo	Equipos	Fórmula mensual
Por horas	TV, aire, luces, termotanque	potencia × horas de uso × días + standby × horas enchufado sin usar
Por ciclos	Lavarropas, secarropas, lavavajillas	kWh por uso × veces por semana ÷ 7 × 30
Etiqueta anual	Heladera, freezer	kWh por año × 30 ÷ 365
Siempre encendido	Router	potencia × 24 h × 30

El cálculo usa un mes tipo de 30 días. La estacionalidad se aplica en el motor de cálculo, pero la interfaz actual simplifica el uso a un mes tipo para que el resultado dependa de lo que el usuario carga y no de la época del año.

La factura se calcula con el cuadro oficial de EDEA:

1. se elige el tramo según el consumo del mes;
2. se suma el cargo fijo del tramo;
3. se calcula el cargo variable y el Cargo Transición Tarifaria;
4. se aplica el subsidio correspondiente, si existe;
5. se aplican los impuestos sobre el subtotal;
6. se obtiene el total y el costo efectivo por kWh.

La aplicación muestra la factura renglón por renglón y permite compararla con una factura real escaneada.

Lectura de facturas y privacidad

La pestaña Factura acepta:

- PDF digital;
- foto JPG, PNG o WebP;
- cámara del celular cuando la aplicación se usa por HTTPS.

El procesamiento es el siguiente:

1. si es PDF, se extrae el texto con `pypdf`;
2. si es imagen, se preprocesa y se aplica OCR con Tesseract en español;
3. se leen códigos QR y de barras con `zxing-cpp`;
4. se buscan consumo, período, importe, vencimiento y subsidio;
5. se muestran los datos detectados con un nivel de confianza;

6. el usuario revisa y corrige;
7. recién entonces se usan los datos para comparar o calibrar.

La factura se procesa en memoria y no se guarda. El texto completo, que puede contener nombre, dirección y NIS, se descarta. Solo se conservan los campos numéricos y los renglones necesarios para dibujar la boleta.

Si Tesseract no está instalado, la aplicación sigue funcionando con PDF y con carga manual.

Verificación y reproducibilidad

Pruebas automatizadas

Se ejecutó la suite completa:

```
python -m unittest discover -s tests -v
```

Resultado: **33 pruebas aprobadas**.

Las pruebas cubren:

- cálculo de consumo activo y pasivo;
- ejemplo de la propuesta con cuatro artefactos;
- ejemplo de los tres escenarios tarifarios;
- factura real de EDEA;
- impuestos de una boleta real;
- separación mensual y anual del tope subsidiado;
- independencia de las tarjetas y suma del total;
- curva horaria;
- validación de entradas;
- lectura de facturas con texto, QR y subsidio;
- preparación de ventanas objetivo;
- separación temporal con purga;
- reescalado a la meta argentina.

Ejemplos verificados

Tabla 17

Ejemplos verificados mediante pruebas automatizadas

Ejemplo	Esperado	Resultado
Propuesta 5.2, enero con cuatro artefactos	296,4 kWh	296,4 kWh
Propuesta 5.2, año	2.392,1 kWh	2.392,1 kWh
Propuesta 6.3, 400 kWh sin subsidio	$ 78.650	$ 78.650
Propuesta 6.3, 400 kWh subsidio nacional	$ 53.240	$ 53.240
Propuesta 6.3, 400 kWh tarifa social provincial	$ 45.617	$ 45.617
Factura EDEA, 273 kWh sin subsidio	$ 116.716	$ 116.716
Impuestos de una boleta real, subtotal $ 41.383,55	$ 22.554,45	$ 22.554,45

Reproducción del entrenamiento

El notebook `notebooks/entrenamiento_modelos.ipynb` ejecuta el flujo completo. También puede correrse:

```
python entrenamiento_modelos.py
```

El script:

- lee el dataset local o lo descarga de UCI;
- audita la calidad de los datos;
- reescala la energía a un hogar argentino;
- arma las filas supervisadas;
- separa entrenamiento, validación y prueba;
- entrena todos los candidatos;
- informa las métricas;
- guarda en `modelos/` el regresor y el clasificador elegidos en validación.

El notebook no sobrescribe los modelos de producción; el script sí los genera. La aplicación solo carga los `.pkl` propios del proyecto y no acepta archivos externos.

Requisitos

El archivo `requirements.txt` fija las versiones:

```
streamlit==1.57.0
plotly==6.7.0
pandas==2.3.1
pypdf==6.21.2
pytesseract==0.3.13
Pillow==11.3.0
scikit-learn==1.8.0
joblib==1.5.3
numpy==2.3.2
zxing-cpp==3.1.1
```

`packages.txt` instala Tesseract con español en Streamlit Community Cloud.

Despliegue

La aplicación está publicada en:

https://me-paso-consumo-energia-tiago.streamlit.app/

El despliegue se realizó desde el repositorio de GitHub, con Python 3.12. Streamlit Community Cloud redepliega automáticamente al hacer push a la rama configurada.

La aplicación se verificó en teléfonos. La cámara de la pestaña Factura funciona en la versión publicada porque utiliza HTTPS; en la red local se recomienda usar la opción de subir un PDF o una foto.

Las casas guardadas se escriben en la carpeta `sesiones/` del servidor. En Community Cloud ese almacenamiento no es persistente ante reinicios o recreaciones del entorno. Por eso el enlace de una casa debe considerarse temporal hasta incorporar una base de datos persistente.

Para la entrega final conviene verificar que el commit con la última versión esté subido a la rama publicada y que Community Cloud haya terminado el redepliegue.

Limitaciones

Las limitaciones son parte central de este trabajo y se declaran explícitamente.

Limitaciones de los datos

1. **Un solo hogar.** Los modelos aprendieron de una única vivienda de Sceaux, Francia. No representan una muestra de hogares argentinos.
2. **Datos de 2006 a 2010.** El clima, los artefactos, las costumbres y las tarifas son distintos de los actuales.
3. **Reescalado artificial.** Multiplicar la energía por 0,514 permite que la mediana coincida con la meta argentina, pero no convierte al hogar francés en un hogar argentino. Es un ajuste metodológico, no datos nuevos.
4. **Cambio de distribución.** La proporción de excesos fue 49,1 % en entrenamiento, 70,5 % en validación y 34,2 % en prueba. El desempeño no es estable entre períodos.
5. **Valores estándar de eficiencia.** Los datos de heladeras, freezers, aires y televisores provienen del mercado australiano y neozelandés, no de etiquetas IRAM argentinas.

Limitaciones de la predicción

1. **Variables imputadas.** La aplicación no tiene un medidor doméstico. El consumo de la semana anterior se aproxima con el consumo actual; la energía reactiva se fija en 1,5 kVArh por día; el voltaje se fija en 240 V.
2. **Temperatura manual.** La temperatura de hoy y de mañana se ingresan a mano. El valor inicial es 20 °C.
3. **Estaciones invertidas.** El mes se corre seis meses para pasar del hemisferio sur al norte. En Francia el verano es la época de menor consumo, por lo que el modelo puede subestimar una casa argentina con aire acondicionado.
4. **KNN no extrapola.** El modelo no predice valores fuera del rango de los días de entrenamiento. Puede sobreestimar casas de muy bajo consumo.
5. **Errores cerca de la meta.** Un error pequeño puede cambiar la alerta. La zona gris comunica esa incertidumbre, pero no la elimina.
6. **Feriados.** El entrenamiento usó feriados franceses; la aplicación usa feriados argentinos de fecha fija. Al reentrenar conviene unificar el criterio.
7. **Factor de potencia.** La aplicación no mide el cos φ real de la vivienda ni muestra un indicador de recargo. Usa la energía reactiva típica del dataset para alimentar el modelo. El recargo por bajo factor de potencia no se calcula porque todavía falta definir con precisión el régimen de OCEBA.

Limitaciones de la aplicación

1. **Sin base de datos.** El estado vive en la sesión y en archivos JSON locales. Al cerrar la pestaña se pierde la casa salvo que se use el enlace guardado.
2. **Persistencia en la nube.** El disco de Community Cloud no es permanente.
3. **OCR.** Las fotos borrosas, torcidas o con sombras pueden producir errores. El PDF digital es más preciso. La lectura se probó con facturas de prueba; conviene validarla con más facturas reales de EDEA.
4. **Catálogo.** Algunos valores son supuestos y no mediciones de una vivienda concreta.
5. **Cálculo determinista.** La estimación mensual depende de las horas y potencias que carga el usuario. No es una medición real.
6. **Dos conceptos distintos.** El cálculo de factura no es una predicción de aprendizaje automático. La predicción estadística es la del paso 4.

Mejoras futuras

Tabla 18

Mejoras futuras propuestas

Mejora	Para qué
Entrenar con más hogares y datos argentinos	Mejorar la representatividad
Incorporar un hogar con aire acondicionado	Corregir la subestimación de verano
Usar el historial real de la casa o de facturas anteriores	Reemplazar la aproximación de la semana anterior
Estimar la energía reactiva y el cos φ por electrodoméstico	Mostrar el indicador y evaluar un posible recargo
Traer temperatura y pronóstico desde Open-Meteo	Evitar la carga manual
Reentrenar con feriados argentinos	Coherencia entre entrenamiento y aplicación
Probar modelos que extrapolen	Mejorar casas de muy bajo consumo
Validar por estaciones	Ver en qué época falla más cada modelo
Incorporar una base de datos	Persistir las casas guardadas en la nube
Agregar pruebas de `simulador/prediccion.py`	Cubrir el armado de las 16 variables
Probar el OCR con más facturas reales	Medir precisión por campo
Actualizar el cuadro tarifario automáticamente	Mantener vigentes los costos

Respuestas a las preguntas de la consigna

¿El modelo de regresión supera al baseline?

Sí. El KNN k=50 obtuvo un MAE de 2,249 kWh en prueba, frente a 3,165 kWh del `DummyRegressor`. También superó al KNN k=25, que obtuvo 2,345 kWh.

¿Qué significa el MAE en el contexto elegido?

Significa que la estimación se equivoca, en promedio, unos 2,25 kWh por día. En una casa de 13,33 kWh diarios, ese error es relevante. Cerca de la meta, un error de ese tamaño puede invertir la alerta.

¿Qué modelo detecta mejor los casos críticos?

El clasificador directo GaussianNB. Su recall fue 0,700, frente a 0,577 de la regresión + umbral. Detectó 1.168 excesos de 1.669 casos reales de exceso, aunque generó 779 falsos positivos.

¿Qué errores son más costosos?

Los falsos negativos. Se les asignó un peso de 3 frente a 1 de los falsos positivos, porque implican no advertir un gasto que puede tener consecuencias económicas. Los falsos positivos cuestan comodidad o una advertencia innecesaria.

¿Qué sucede con los casos cercanos al umbral?

Se concentran los desacuerdos y los errores. Un caso real de 13,341 kWh, apenas 0,007 kWh por encima de la meta, no fue detectado por ninguna de las dos alertas. La aplicación marca una zona gris cuando la estimación está dentro del MAE.

¿Es posible obtener un buen MAE y una mala clasificación?

Sí. Un modelo puede tener un error absoluto medio bajo y, aun así, equivocarse en los casos cercanos al umbral. La clasificación depende de la posición relativa respecto de la meta, no solo del tamaño del error.

¿Qué sistema recomendarían y por qué?

Con la ponderación 3:1 y en el período de prueba, el clasificador directo tuvo menor costo (2.282 frente a 2.706) y mayor recall. Se recomienda como alerta principal, pero con cautela: produce más falsas alarmas y la proporción de excesos cambia entre períodos. La regresión sigue siendo útil para comunicar la magnitud esperada y el costo.

¿En qué situaciones no debería utilizarse la solución?

- en otro hogar sin reentrenar;
- sin los datos de las últimas 24 horas;
- durante los primeros días de adaptación a un artefacto nuevo;
- en vacaciones o ausencias prolongadas;
- en casas de muy bajo consumo, por la tendencia de KNN a sobreestimar;
- en verano con aire acondicionado, por la tendencia a subestimar;
- para reclamar formalmente un recargo o una factura, porque la medición válida es la del medidor de la distribuidora.

Bitácora de decisiones

Tabla 19

Bitácora de decisiones

Fecha	Decisión	Alternativas	Justificación	Resultado
13/10/2026	Formular el proyecto como asistente de consumo eléctrico	Otros temas del listado de la consigna	Había una necesidad concreta, datos públicos y un umbral tarifario justificable	Propuesta inicial del problema y del usuario
15/10/2026	Crear el repositorio y la estructura base	Desarrollo sin control de versiones	La consigna exige repositorio y entregas progresivas	Commit inicial
17/10/2026	Separar cálculo, estado, interfaz y datos	Un único archivo monolítico	Facilitar pruebas, mantenimiento y trabajo grupal	Módulos `simulador/` y páginas
20/10/2026	Documentar el proyecto y limpiar archivos	Documentación dispersa	Mejorar la reproducibilidad y la entrega	README y guías de ejecución
27/10/2026	Integrar regresión y clasificación en Mi casa	Mostrar solo una predicción	La consigna exige comparar ambos sistemas	Paso 4 con semáforo y comparación
30/10/2026	Incorporar notebook, análisis y pruebas	Dejar solo el script de entrenamiento	La consigna exige notebook ejecutable y evidencia	Notebook, README de análisis y suite de pruebas
1/11/2026	Cambiar la meta a 13,33 kWh y reescalar el dataset	Mantener la mediana original de 25,92 kWh	400 kWh es el límite del tramo R3 de EDEA y tiene consecuencia tarifaria	Modelos reentrenados y métricas en escala argentina
1/11/2026	Usar la energía reactiva típica en lugar del cos φ fijo de 0,95	Mantener el valor fijo	El valor fijo hacía fallar al clasificador	Clasificador coherente con el entrenamiento
1/11/2026	Reemplazar las tarifas de ejemplo por el cuadro real de EDEA	Mantener el esquema simplificado de la propuesta	La factura debía reflejar la boleta real	Cálculo por tramos, subsidios e impuestos
2/11/2026	Revisar y ampliar las pruebas	Confiar solo en la ejecución manual	La consigna exige reproducibilidad	33 pruebas aprobadas
3/11/2026	Preparar el informe final y la entrega	Entregar solo el repositorio	La consigna exige informe, bitácora y distribución de tareas	Documento final

Distribución de tareas

La siguiente distribución se reconstruyó a partir de los commits, los documentos y los módulos del repositorio. El grupo puede ajustar la redacción final si alguna tarea se organizó de otra manera.

Tabla 20

Distribución de tareas por integrante

Integrante	Tareas principales
Tiago Maidana	Coordinación general, arquitectura Streamlit, motor de cálculo y facturación EDEA, integración de la predicción, documentación técnica, despliegue y mantenimiento del repositorio
Rodrigo Bulggiani	Pantalla de Inicio, navegación, revisión de interfaz y experiencia de usuario
Romina Guzmán	Propuesta inicial, catálogo de electrodomésticos, carga y revisión de datos
Francisco Elías Campos	Formulación del problema y del usuario, propuesta metodológica, definición del umbral, variables y esquema de costos, revisión del informe
Juan M. Flescia	Revisión de modelos y métricas, pruebas de calidad, verificación de la aplicación y preparación de la defensa

Todas las personas deben poder explicar cualquier parte del trabajo: datos, preparación, separación, modelos, métricas, errores, aplicación y despliegue.

Conclusión

El trabajo desarrolló una solución completa de aprendizaje automático aplicada al consumo eléctrico hogareño. La aplicación permite comprender el consumo, estimar la factura, comparar escenarios tarifarios y anticipar si se superará una meta diaria.

Los dos modelos cumplen tareas complementarias:

- la regresión KNN k=50 estima la energía esperada y supera al baseline;
- el clasificador GaussianNB responde directamente si se supera la meta y detecta más casos críticos.

La comparación integrada mostró que el clasificador directo tuvo menor costo ponderado en el período de prueba, aunque con más falsas alarmas y con el riesgo de que la distribución cambie entre períodos. La aplicación presenta ambas respuestas y un semáforo para comunicar la incertidumbre.

El proyecto también reconoce sus límites: los modelos provienen de un solo hogar francés, el reescalado es un ajuste metodológico, algunas variables se imputan y el verano argentino con aire acondicionado puede quedar subestimado. Estas limitaciones no invalidan el trabajo, pero sí delimitan su alcance: es un prototipo educativo y analítico, no una herramienta de facturación ni una medición oficial.

La entrega incluye repositorio, aplicación publicada, modelos entrenados, notebook

reproducible, requirements, pruebas automatizadas, informe, bitácora y distribución de tareas.

Referencias

Gobierno de Australia. (s. f.). *Energy rating for household appliances* [Conjunto de datos]. data.gov.au. https://data.gov.au/data/dataset/energy-rating-for-household-appliances

Maidana, T., Bulggiani, R., Guzmán, R., Elías Campos, F., & Flescia, J. M. (2026a). *¿Me paso o no me paso?* [Aplicación web]. Streamlit Community Cloud. https://me-paso-consumo-energia-tiago.streamlit.app/

Maidana, T., Bulggiani, R., Guzmán, R., Elías Campos, F., & Flescia, J. M. (2026b). *trabajo-integrador-consumo-energia* [Código fuente]. GitHub. https://github.com/TiagoM395/trabajo-integrador-consumo-energia

Open-Meteo. (s. f.). *Open-Meteo*. https://open-meteo.com/

Organismo de Control de Energía Eléctrica de la Provincia de Buenos Aires. (2026). *Resolución MIySP N.º 682/2026* [Cuadro tarifario]. https://oceba.gba.gov.ar/nueva_web/adjuntos/ct202609/IF-2026-27778457-GDEBA-GMOCEBA.pdf

Organismo de Control de Energía Eléctrica de la Provincia de Buenos Aires. (s. f.). *Cuadros tarifarios*. https://oceba.gba.gov.ar/nueva_web/s.php?i=17

scikit-learn developers. (s. f.). *scikit-learn: Machine learning in Python*. https://scikit-learn.org/stable/

Streamlit. (s. f.). *Streamlit documentation*. https://docs.streamlit.io/

UCI Machine Learning Repository. (s. f.). *Individual household electric power consumption* [Conjunto de datos]. https://archive.ics.uci.edu/dataset/235/individual+household+electric+power+consumption

Apéndice A

Diccionario de datos del dataset original

Tabla A1

Columnas del conjunto de datos original

Columna original	Descripción	Uso
`Date`	Fecha de la medición	Construcción de hora, día, mes y feriados
`Time`	Hora de la medición	Agregación horaria
`Global_active_power`	Potencia activa media, en kW	Objetivo y variables de historial
`Global_reactive_power`	Potencia reactiva media, en kVAr	Variable reactiva y cos φ
`Voltage`	Voltaje medio, en V	Variable de voltaje
`Global_intensity`	Intensidad media, en A	Descartada para evitar fuga
`Sub_metering_1`	Energía de cocina, en Wh/min	Submedidor 1
`Sub_metering_2`	Energía de lavadero, heladera y luces, en Wh/min	Submedidor 2
`Sub_metering_3`	Energía de termotanque y climatización, en Wh/min	Submedidor 3

Apéndice B

Diccionario de variables del modelo

Tabla B1

Variables del modelo

Variable	Tipo	Origen
kwh_h	Numérica	Consumo de la hora de consulta
active_24	Numérica	Suma de las últimas 24 horas
active_prevweek	Numérica	Mismas 24 horas de la semana anterior
reactive_24	Numérica	Suma de reactiva de las últimas 24 horas
cosphi_24	Numérica	Derivada de activa y reactiva
sub1_24	Numérica	Submedidor de cocina
sub2_24	Numérica	Submedidor de lavadero, heladera y luces
sub3_24	Numérica	Submedidor de termotanque y clima
volt_24	Numérica	Voltaje medio de las últimas 24 horas
hour	Numérica	Hora del día
dayofweek	Numérica	Día de la semana
month	Numérica	Mes
is_weekend	Binaria	Fin de semana
is_feriado	Binaria	Feriado
temp_actual	Numérica	Temperatura actual
temp_next24	Numérica	Temperatura de las próximas 24 horas

Variable objetivo de regresión: `target_kwh_next24`. Variable objetivo de clasificación: `target_exceso`.

Apéndice C

Comandos de ejecución

```
# Crear entorno virtual
python -m venv .venv

# Activar en Windows
.venv\Scripts\activate

# Instalar dependencias
pip install -r requirements.txt

# Ejecutar la aplicación
streamlit run streamlit_app.py

# Ejecutar las pruebas
python -m unittest discover -s tests -v

# Reproducir el entrenamiento
python entrenamiento_modelos.py
```

Para leer fotos de facturas en una PC con Windows se necesita Tesseract OCR con español. Sin Tesseract, la aplicación sigue funcionando con PDF y carga manual.